

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ**

Федеральное государственное автономное образовательное учреждение высшего образования

Санкт-Петербургский национальный исследовательский университет ИТМО

Мегафакультет трансляционных информационных технологий

Факультет информационных технологий и программирования

Отчет по лабораторной работе №2

По дисциплине “Теория массового обслуживания”

Выполнил студент группы М3303

Лукин Даниил Валерьевич

Проверил

Глазков А.Н.



УНИВЕРСИТЕТ ИТМО

Санкт-Петербург

2026

Введение

Цель работы — исследовать характеристики многоканальной системы массового обслуживания с ожиданием типа $M/M/n/\infty$ с использованием аналитической модели и имитационного моделирования.

Основные задачи работы:

- построить математическую модель системы с неограниченной очередью;
- рассчитать основные характеристики системы;
- сравнить теоретические значения с результатами моделирования;
- исследовать влияние числа каналов, интенсивности входящего потока и интенсивности обслуживания на работу системы.

В качестве прикладного примера рассматривается сервер обработки запросов к **key-value** хранилищу. Каждая заявка проходит три стадии: прием RPC-запроса, выполнение команды и формирование ответа клиенту.

Описание системы

Исследуемая система моделируется как многоканальная СМО с ожиданием $M/M/n/\infty$:

- входной поток заявок является пуассоновским с интенсивностью λ ;
- число каналов обслуживания равно n ;
- очередь ожидания не ограничена;
- порядок обслуживания заявок — FIFO;
- для теоретических расчетов используется эффективная интенсивность обслуживания одного канала μ_{eff} .

В базовом режиме используются следующие параметры:

Параметр	Значение
λ	10.0 qps
n	4
μ_{rpc}	30.0 qps
μ_{resp}	40.0 qps
Размер базы данных	1000
Время моделирования	3000.0 с
Число прогонов	12

Далее в отчёте интенсивности указаны в qps (заявок в секунду), а временные характеристики — в миллисекундах.

Математическая модель

Входной поток

Пуассоновский поток заявок описывается соотношением

$$P(N(t) = k) = \left(\frac{(\lambda t)^k}{k!} \right) e^{-\lambda t}.$$

Интервалы между поступлениями имеют экспоненциальное распределение:

$$f(t) = \lambda e^{-\lambda t}, \quad t \geq 0.$$

Обслуживание заявки

Полное время обслуживания одной заявки складывается из трех частей:

$$S = S_{\text{rpc}} + S_{\text{exec}} + S_{\text{resp}}.$$

Здесь:

- S_{rpc} — время обработки входного RPC-запроса;
- S_{exec} — время выполнения команды;
- S_{resp} — время подготовки и отправки ответа.

Для команд используются вероятности:

Команда	Вероятность	Комментарий
GET	0.80	Чтение значения
SET	0.15	Запись значения
DELETE	0.05	Удаление значения

Среднее время обслуживания оценивается моделированием, после чего вводится эффективная интенсивность обслуживания одного канала:

$$\mu_{\text{eff}} = \frac{1}{E[S]}.$$

Теоретические характеристики

Для аналитической части используется формула Эрланга С. Введем обозначения:

$a = \frac{\lambda}{\mu_{\text{eff}}}$ — приведенная нагрузка.

$\rho = \frac{\lambda}{n\mu_{\text{eff}}}$ — коэффициент загрузки одного канала.

- нагрузка a показывает, сколько каналов было бы занято в среднем при данном входном потоке и данной скорости обслуживания;
- загрузка ρ показывает, какую долю времени в среднем занят один канал.

Эти величины связаны соотношением:

$$a = n\rho.$$

Следовательно, нагрузка измеряется в среднем числе занятых каналов, а загрузка является безразмерной величиной и обычно принимает значения от 0 до 1 в устойчивом режиме.

Условие устойчивости системы:

$$\lambda < n\mu_{\text{eff}} \Leftrightarrow \rho < 1.$$

Вероятность простоя системы:

$$P_0 = \frac{1}{\sum_{k=0}^{n-1} \left(\frac{a^k}{k!} \right) + \left(\frac{a^n}{n!(1-\rho)} \right)}.$$

Вероятность ожидания заявки в очереди:

$$P_{\text{wait}} = \left(\frac{a^n}{n!(1-\rho)} \right) P_0.$$

Средняя длина очереди:

$$L_q = P_{\text{wait}} \left(\frac{\rho}{1-\rho} \right).$$

Среднее число заявок в системе:

$$L = L_q + a.$$

Среднее время ожидания и среднее время пребывания заявки в системе:

$$W_q = \frac{L_q}{\lambda},$$

$$W = W_q + \frac{1}{\mu_{\text{eff}}}.$$

Вывод формул для многоканальной СМО с ожиданием

Ниже приведен краткий вывод основных формул для системы М/М/п/∞, использованный в работе. По структуре он соответствует стандартному выводу для многоканальной СМО с ожиданием через стационарные вероятности состояний и согласуется с материалом из пособия Солнышкиной.

Рассмотрим состояния системы по числу заявок, находящихся в системе. Обозначим через p_k стационарную вероятность того, что в системе находится ровно k заявок.

Так как входной поток является пуассоновским с интенсивностью λ , а интенсивность обслуживания одной заявки равна μ_{eff} , процесс изменения числа заявок является процессом рождения-гибели.

Для состояний $k < n$ все поступившие заявки либо находятся на обслуживании, либо система частично свободна. Тогда интенсивность выхода из состояния k равна $k\mu_{\text{eff}}$, и стационарные вероятности удовлетворяют рекуррентному соотношению

$$\lambda p_k = (k + 1)\mu_{\text{eff}} p_{k+1}, \quad k = 0, 1, \dots, n - 1.$$

Отсюда последовательно получаем:

$$p_1 = \left(\frac{\lambda}{\mu_{\text{eff}}} \right) p_0 = a p_0,$$

$$p_2 = \left(\frac{a^2}{2!} \right) p_0,$$

$$p_k = \left(\frac{a^k}{k!} \right) p_0, \quad k = 0, 1, \dots, n,$$

где $a = \frac{\lambda}{\mu_{\text{eff}}}$ — приведенная нагрузка.

Если $k \geq n$, то все n каналов заняты, а остальные заявки находятся в очереди. В этом случае суммарная интенсивность обслуживания не растет и равна $n\mu_{\text{eff}}$. Поэтому:

$$\lambda p_k = n\mu_{\text{eff}} p_{k+1}, \quad k \geq n.$$

Следовательно,

$$p_{n+r} = p_n \left(\frac{\lambda}{n\mu_{\text{eff}}} \right)^r = p_n \rho^r, \quad r = 0, 1, 2, \dots,$$

где $\rho = \frac{\lambda}{n\mu_{\text{eff}}}$ — коэффициент загрузки одного канала.

Подставляя выражение для p_n , получаем:

$$p_{n+r} = \left(\frac{a^n}{n!} \right) \rho^r p_0.$$

Для существования стационарного режима необходимо, чтобы хвостовой геометрический ряд сходил, то есть

$$\rho < 1 \Leftrightarrow \lambda < n\mu_{\text{eff}}.$$

Теперь используем условие нормировки:

$$\sum_{k=0}^{\infty} p_k = 1.$$

Разделяя сумму на две части, получаем:

$$\sum_{k=0}^{n-1} p_k + \sum_{r=0}^{\infty} p_{n+r} = 1.$$

Подставляя найденные выражения для вероятностей состояний:

$$p_0 \sum_{k=0}^{n-1} \left(\frac{a^k}{k!} \right) + p_0 \left(\frac{a^n}{n!} \right) \sum_{r=0}^{\infty} \rho^r = 1.$$

Так как для $|\rho| < 1$

$$\sum_{r=0}^{\infty} \rho^r = \frac{1}{1-\rho},$$

получаем формулу для вероятности простоя:

$$P_0 = p_0 = \frac{1}{\sum_{k=0}^{n-1} \left(\frac{a^k}{k!} \right) + \frac{a^n}{n!(1-\rho)}}.$$

Вероятность ожидания равна вероятности того, что все каналы заняты, то есть система находится в одном из состояний $n, n+1, \dots$:

$$P_{\text{wait}} = \sum_{r=0}^{\infty} p_{n+r}.$$

Подставляя выражение для p_{n+r} , имеем:

$$P_{\text{wait}} = \left(\frac{a^n}{n!} \right) p_0 \sum_{r=0}^{\infty} \rho^r = \left(\frac{a^n}{n!(1-\rho)} \right) p_0.$$

Среднее число заявок в очереди определяется как

$$L_q = \sum_{r=1}^{\infty} r p_{n+r}.$$

После подстановки формулы для p_{n+r} :

$$L_q = \left(\frac{a^n}{n!} \right) p_0 \sum_{r=1}^{\infty} r \rho^r.$$

Используя известную сумму ряда

$$\sum_{r=1}^{\infty} r \rho^r = \frac{\rho}{(1-\rho)^2}, \quad |\rho| < 1,$$

получаем:

$$L_q = \left(\frac{a^n}{n!} \right) p_0 \frac{\rho}{(1 - \rho)^2}.$$

Так как

$$P_{\text{wait}} = \left(\frac{a^n}{n!(1 - \rho)} \right) p_0,$$

то формулу для средней длины очереди удобно переписать в виде

$$L_q = P_{\text{wait}} \frac{\rho}{1 - \rho}.$$

Среднее число занятых каналов равно приведенной нагрузке:

$$Z = \frac{\lambda}{\mu_{\text{eff}}} = a.$$

Тогда среднее число заявок в системе:

$$L = L_q + Z = L_q + a.$$

Наконец, по формулам Литтла:

$$W_q = \frac{L_q}{\lambda},$$

$$W = \frac{L}{\lambda} = W_q + \frac{1}{\mu_{\text{eff}}}.$$

Именно эти выражения используются далее при сравнении теоретической модели с результатами имитационного моделирования.

Имитационная модель

Имитационная модель реализована как событийная симуляция. В каждый момент времени отслеживаются:

- поступления новых заявок;
- завершения обслуживания на каналах;
- длина очереди;
- число занятых каналов;
- времена ожидания и пребывания заявок в системе.

Для повышения устойчивости оценки характеристики вычисляются как средние значения по нескольким независимым прогонам с фиксированными начальными зернами генератора случайных чисел.

Результаты моделирования

Оценка $E[S]$ и μ_{eff}

По результатам моделирования получены следующие оценки:

Характеристика	Значение
$E[S]$	207.473 мс
μ_{eff}	4.819904 qps
$a = \frac{\lambda}{\mu_{\text{eff}}}$	2.074730
$\rho = \frac{\lambda}{n\mu_{\text{eff}}}$	0.518683

Полученное значение $\rho < 1$, следовательно, базовый режим является устойчивым.

Сравнение теории и имитации

Характеристика	Симуляция	Теория	Абс. отклонение
P_0	0.120027	0.120201	0.000173
P_{wait}	0.188974	0.192801	0.003827
L_q	0.162439	0.207769	0.045329
L	2.234519	2.282499	0.047980
W_q	16.230 мс	20.777 мс	4.547 мс
W	223.266 мс	228.250 мс	4.984 мс
Среднее число занятых каналов	2.072080	2.074730	0.002650
ρ	0.518020	0.518683	0.000663

Сравнение показывает хорошее согласование имитационной модели с формулами Эрланга С. Наиболее заметное различие наблюдается для L_q , однако даже в этом случае отклонение остается умеренным и не меняет качественных выводов о режиме работы системы.

Влияние числа каналов обслуживания

Результаты исследования зависимости характеристик от числа каналов приведены в таблице.

n	W_q сим.	W_q теор.	L_q сим.	L_q теор.
1	773307.080 мс	inf	7709.581628	inf
2	49932.688 мс	inf	500.766696	inf
3	85.540 мс	107.643 мс	0.853689	1.076429
4	16.513 мс	20.777 мс	0.164871	0.207769
5	4.015 мс	4.833 мс	0.040303	0.048333
6	0.935 мс	1.122 мс	0.009383	0.011219
7	0.206 мс	0.247 мс	0.002057	0.002468
8	0.048 мс	0.051 мс	0.000479	0.000506

Анализ результатов показывает:

- при $n = 1$ и $n = 2$ система неустойчива, так как $\rho \geq 1$, поэтому теоретические значения W_q и L_q стремятся к бесконечности;
- в имитации для неустойчивых режимов получаются очень большие, но конечные значения, так как моделирование ограничено конечным временем;
- начиная с $n = 3$ система становится устойчивой;
- увеличение числа каналов с 4 до 6 снижает среднее время ожидания примерно в 19 раз: с 16.513 мс до 0.935 мс;
- дальнейший рост числа каналов продолжает уменьшать очередь, однако эффект постепенно становится менее заметным.

Построенные в ноутбуке графики $W_{q(n)}$ и $L_{q(n)}$ подтверждают резкое снижение времени ожидания и длины очереди при росте числа каналов.

Влияние интенсивности входящего потока

Зависимость характеристик от интенсивности входящего потока представлена ниже:

λ	W_q сим.	W_q теор.	L_q сим.	ρ теор.
4.0 qps	0.615 мс	0.711 мс	0.002450	0.207473
6.0 qps	2.639 мс	3.138 мс	0.015915	0.311210
8.0 qps	7.430 мс	8.974 мс	0.059381	0.414946
10.0 qps	16.798 мс	20.777 мс	0.168150	0.518683
12.0 qps	34.997 мс	43.462 мс	0.419760	0.622419
14.0 qps	71.715 мс	89.043 мс	1.005644	0.726156
16.0 qps	151.322 мс	198.583 мс	2.416549	0.829892
18.0 qps	531.184 мс	669.671 мс	9.567791	0.933629

Из таблицы и графиков видно, что:

- при росте λ коэффициент загрузки ρ монотонно увеличивается;
- среднее время ожидания W_q растет нелинейно и особенно быстро увеличивается при приближении ρ к единице;
- при увеличении λ от 10 до 18 средняя длина очереди возрастает с 0.168150 до 9.567791, то есть более чем в 50 раз;
- при $\lambda = 18$ система остается устойчивой, но уже работает близко к границе устойчивости.

Влияние интенсивности обслуживания

Для исследования влияния скорости обслуживания в ноутбуке использовался масштабный множитель, изменяющий эффективную интенсивность обслуживания. Результаты приведены ниже:

μ_{eff}	scale	W_q сим.	L_q сим.	ρ теор.
3.600731 qps	0.75	73.698 мс	0.737935	0.694303
4.345919 qps	0.90	28.642 мс	0.287116	0.575252
4.829344 qps	1.00	16.798 мс	0.168150	0.517669
5.312746 qps	1.10	10.528 мс	0.105233	0.470566
6.052766 qps	1.25	5.830 мс	0.058368	0.413034
7.246354 qps	1.50	2.610 мс	0.026166	0.345001

По результатам моделирования:

- увеличение μ_{eff} приводит к уменьшению загрузки каналов;
- при росте μ_{eff} примерно с 4.83 до 7.25 qps среднее время ожидания уменьшается с 16.798 мс до 2.610 мс;
- рост интенсивности обслуживания является эффективным способом уменьшения очереди даже без изменения числа каналов.

Контрольные сценарии

Для наглядного сравнения были рассмотрены несколько режимов работы:

Сценарий	ρ	W_q сим.	W_q теор.	L_q сим.
Высокая нагрузка, мало каналов	1.031305	53132.498 мс	inf	531.183903
Базовый режим	0.520078	16.761 мс	21.051 мс	0.167419
Больше каналов	0.345063	0.875 мс	1.108 мс	0.008740
Быстрое обслуживание	0.397335	4.844 мс	5.861 мс	0.048441
Почти граница устойчивости	0.957504	914.044 мс	1105.155 мс	16.930047

Эта таблица показывает два важных эффекта:

- режим с малым числом каналов и высокой нагрузкой фактически непригоден для эксплуатации;
- увеличение числа каналов или ускорение обслуживания резко уменьшает очередь и время ожидания;
- даже оставаясь в устойчивой области, система при ρ около 0.95 уже демонстрирует очень большие очереди и заметные задержки.

Анализ результатов

На основании проведенных экспериментов можно сделать следующие выводы.

1. Имитационная модель корректно воспроизводит поведение многоканальной СМО с ожиданием. Для базового режима отклонения между теорией и симуляцией малы по всем ключевым характеристикам.
2. Основным фактором, определяющим эффективность системы, является коэффициент загрузки канала $\rho = \frac{\lambda}{n\mu_{\text{eff}}}$. Пока ρ далек от единицы, очередь остается небольшой. При приближении к единице длина очереди и время ожидания быстро возрастают.
3. Увеличение числа каналов обслуживания дает наиболее сильный эффект в зоне, где система только выходит из перегрузки. Переход от 2 или 3 каналов к 4–6 каналам резко улучшает характеристики системы.
4. Увеличение интенсивности обслуживания также существенно улучшает работу системы. Этот способ особенно полезен, если число каналов нельзя увеличивать аппаратно или организационно.
5. Для неустойчивых режимов теоретическая модель справедливо показывает бесконечный рост очереди, а имитационная модель на конечном интервале демонстрирует очень большие, но конечные значения.

Заключение

В работе была исследована многоканальная система массового обслуживания с ожиданием типа $M/M/n/\infty$. Построены аналитическая и имитационная модели, выполнено сравнение результатов, а также проведен анализ влияния числа каналов, интенсивности входящего потока и интенсивности обслуживания.

По результатам исследования установлено, что базовый режим с параметрами $\lambda = 10$ qps, $n = 4$ и $\mu_{\text{eff}} \approx 4.82$ qps является устойчивым. Для него коэффициент загрузки одного канала составляет $\rho \approx 0.519$, среднее время ожидания равно примерно 16–21 мс, а средняя длина очереди находится на уровне 0.16–0.21 заявки.

Практический вывод состоит в следующем: для повышения эффективности системы необходимо либо увеличивать число каналов обслуживания, либо ускорять обработку одной заявки. Наиболее опасным является приближение к границе устойчивости $\rho = 1$, так как в этой области даже небольшое увеличение нагрузки приводит к резкому росту задержек и очереди.