

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ**

Федеральное государственное автономное образовательное учреждение высшего образования

Санкт-Петербургский национальный исследовательский университет ИТМО

Мегафакультет трансляционных информационных технологий

Факультет информационных технологий и программирования

Отчет по лабораторной работе №3

По дисциплине “Теория массового обслуживания”

Выполнил студент группы М3303

Лукин Даниил Валерьевич

Проверил

Глазков А.Н.

Санкт-Петербург

2026

Введение

Цель работы — исследовать характеристики системы массового обслуживания с ограниченной очередью типа $M/M/1/m$ и определить минимальную длину очереди, при которой вероятность потерь не превышает заданный порог.

В работе решаются следующие задачи:

- построение математической модели системы $M/M/1/m$;
- расчет основных характеристик системы;
- сравнение теоретических результатов с имитационным моделированием;
- подбор оптимальной длины очереди при ограничении на вероятность потерь.

Так как параметры варианта в репозитории не были найдены, в качестве рабочего набора принят допустимый по потерям режим:

- $\lambda = 3.5$ qps;
- порог вероятности потерь $P_{\text{loss}} \leq 0.05$.

В данной работе m обозначает максимальную длину очереди без учета заявки на обслуживании. Следовательно, полная вместимость системы равна $m + 1$.

В качестве предметной области, как и в предыдущих лабораторных работах, рассматривается сервер обработки запросов к **key-value** базе данных. Клиенты отправляют RPC-запросы на выполнение операций GET, SET и DELETE. В ЛР3 исследуется ситуация, когда у сервера есть только один канал обслуживания и конечный буфер ожидания: если запрос приходит в момент, когда сервер занят и очередь уже заполнена, такой запрос отклоняется.

В отличие от абстрактной модели с заранее заданным μ , в данной работе используется модель обслуживания из ЛР2. Это означает, что время обслуживания одного запроса складывается из:

- приема и разбора RPC-запроса;
- выполнения операции над **key-value** хранилищем;
- формирования и отправки ответа.

По результатам оценки среднего времени обслуживания получено: $E[S] \approx 0.207473$ с.

Эффективная интенсивность обслуживания равна: $\mu_{\text{eff}} = \frac{1}{E[S]} \approx 4.819904$ qps.

При этом предложенная нагрузка системы равна: $\rho = \frac{\lambda}{\mu_{\text{eff}}} \approx 0.726156 < 1$.

Описание модели

Рассматривается одноканальная система массового обслуживания с ограниченной очередью M/M/1/m.

Основные свойства модели:

- входящий поток заявок является пуассоновским;
- время обслуживания имеет экспоненциальное распределение;
- в системе один канал обслуживания;
- в очереди может находиться не более m заявок;
- если в момент поступления канал занят и очередь заполнена, заявка теряется.

В терминах выбранной предметной области это означает следующее:

- заявки представляют собой RPC-запросы клиентов к **key-value** хранилищу;
- канал обслуживания соответствует одному обработчику запросов;
- очередь соответствует ограниченному буферу входящих запросов;
- потеря заявки означает отказ в принятии нового запроса из-за переполнения буфера.

Состояние системы определяется числом заявок в системе. Возможные состояния:

$$0, 1, 2, \dots, m + 1.$$

Здесь:

- состояние 0 означает пустую систему;
- состояния $1, \dots, m + 1$ соответствуют наличию одной заявки на обслуживании и, возможно, заявок в очереди;
- состояние $m + 1$ означает полностью заполненную систему.

Теоретическая часть

Стационарные вероятности

Обозначим через p_k вероятность того, что в системе находится ровно k заявок.

Для теоретического расчета система аппроксимируется моделью М/М/1/т с эффективной интенсивностью обслуживания μ_{eff} , полученной из предметной модели ЛР2.

Для системы М/М/1/т стационарные вероятности имеют вид:

$$p_k = \rho^k p_0, \text{ где } k = 0, 1, \dots, m + 1.$$

Здесь $\rho = \frac{\lambda}{\mu_{\text{eff}}}$ — предложенная нагрузка системы.

Из условия нормировки

$$\sum_{k=0}^{m+1} p_k = 1$$

получаем:

$$p_0 = \frac{1 - \rho}{1 - \rho^{m+2}}, \quad \rho \neq 1.$$

При $\rho = 1$:

$$p_k = \frac{1}{m + 2}.$$

Вывод используемых формул

Так как система М/М/1/т является процессом рождения-гибели, переходы между соседними состояниями происходят следующим образом:

- из состояния k в состояние $k + 1$ система переходит с интенсивностью λ , если буфер ещё не заполнен;
- из состояния k в состояние $k - 1$ система переходит с интенсивностью μ_{eff} , если в системе есть хотя бы одна заявка.

Для стационарного режима выполняются локальные балансовые соотношения:

$$\lambda p_k = \mu_{\text{eff}} p_{k+1}, \quad k = 0, 1, \dots, m.$$

Отсюда сразу следует рекуррентная формула:

$$p_{k+1} = \left(\frac{\lambda}{\mu_{\text{eff}}} \right) p_k = \rho p_k.$$

Последовательно подставляя это равенство, получаем:

$$\begin{aligned} p_1 &= \rho p_0, \\ p_2 &= \rho p_1 = \rho^2 p_0, \\ &\dots \\ p_k &= \rho^k p_0. \end{aligned}$$

Чтобы найти p_0 , используем условие нормировки:

$$\sum_{k=0}^{m+1} p_k = 1.$$

Подставляя найденное выражение для p_k , получаем:

$$p_0 \sum_{k=0}^{m+1} \rho^k = 1.$$

Так как это сумма конечной геометрической прогрессии, имеем:

$$p_0 \frac{1 - \rho^{m+2}}{1 - \rho} = 1, \quad \rho \neq 1.$$

Следовательно,

$$p_0 = \frac{1 - \rho}{1 - \rho^{m+2}}.$$

После этого все остальные характеристики выражаются через найденные стационарные вероятности.

Полная заполненность системы соответствует состоянию $m + 1$, поэтому вероятность потери равна:

$$P_{\text{loss}} = p_{m+1}.$$

Только часть входного потока принимается системой, значит фактическая интенсивность обслуживаемых заявок равна:

$$\lambda_{\text{eff}} = \lambda(1 - P_{\text{loss}}).$$

Среднее число заявок в системе определяется как математическое ожидание числа заявок по состояниям:

$$L = \sum_{k=0}^{m+1} k p_k.$$

Так как в системе один канал, среднее число заявок на обслуживании равно вероятности занятости канала:

$$U = 1 - p_0.$$

Тогда средняя длина очереди находится как разность между средним числом заявок в системе и средним числом заявок на обслуживании:

$$L_q = L - U.$$

После этого по формулам Литтла получаем временные характеристики:

$$W = \frac{L}{\lambda_{\text{eff}}},$$

$$W_q = \frac{L_q}{\lambda_{\text{eff}}}.$$

Именно эти формулы далее используются для аналитических расчётов в работе.

Основные характеристики

В данной работе параметр μ_{eff} интерпретируется как эффективная интенсивность обработки одного запроса к **key-value** базе данных. То есть в величину $\frac{1}{\mu_{\text{eff}}}$ свернуто всё время, которое тратится на:

- прием и разбор RPC-запроса;
- выполнение операции GET, SET или DELETE;
- формирование и отправку ответа клиенту.

Вероятность потери заявки равна вероятности полного заполнения системы:

$$P_{\text{loss}} = p_{m+1}.$$

Фактическая пропускная способность системы:

$$\lambda_{\text{eff}} = \lambda(1 - P_{\text{loss}}).$$

Вероятность занятости канала:

$$U = 1 - p_0.$$

Здесь важно различать нагрузку и загрузку:

- нагрузка $\rho = \frac{\lambda}{\mu_{\text{eff}}}$ показывает отношение интенсивности входящего потока к эффективной интенсивности обслуживания;
- загрузка U показывает, какую долю времени сервер реально занят в системе с потерями.

Среднее число заявок в системе:

$$L = \sum_{k=0}^{m+1} k p_k.$$

Среднее число заявок в очереди:

$$L_q = L - U.$$

По формулам Литтла:

$$W = \frac{L}{\lambda_{\text{eff}}},$$

$$W_q = \frac{L_q}{\lambda_{\text{eff}}}.$$

Критерий оптимальности

Оптимальная длина очереди выбирается как минимальное значение m , при котором выполняется условие:

$$P_{\text{loss}} \leq 0.05.$$

Именно такое правило используется в данной работе.

Однако для текущих параметров важно дополнительно проверить, достижимо ли это условие в принципе. Если $\lambda < \mu_{\text{eff}}$, то система не перегружена, и при достаточно большом буфере вероятность потерь может быть снижена до сколь угодно малого уровня.

В пределе при $m \rightarrow \infty$ для устойчивой одноканальной системы вероятность потерь стремится к нулю:

$$P_{\text{loss}} \rightarrow 0.$$

Следовательно, при текущих параметрах задача подбора длины очереди имеет допустимое решение.

Имитационная модель

Имитационная модель реализована как событийная симуляция с двумя типами событий:

- поступление новой заявки;
- завершение обслуживания.

Если в момент прихода новой заявки:

- канал свободен, заявка сразу идет на обслуживание;
- канал занят, но в очереди есть место, заявка становится в очередь;
- канал занят и очередь заполнена, заявка теряется.

С прикладной точки зрения это моделирует сервер **key-value** базы, у которого имеется один обработчик запросов и конечный входной буфер. Если буфер заполнен, новый RPC-запрос не может быть поставлен в очередь и считается потерянным.

По результатам моделирования оцениваются:

- вероятность потерь;
- средняя длина очереди;
- среднее время ожидания;
- среднее время пребывания заявки в системе;
- фактическая загрузка и пропускная способность.

Для уменьшения случайных отклонений использовалось усреднение по 20 независимым прогонам при времени моделирования 5000 с.

Результаты

Базовый режим при $m = 5$

Показатель	Теория	Имитация	Абс. отклонение
P_{loss}	0.044934	0.028925	0.016009
L_q	1.124127	0.997796	0.126331
W_q	336.290 мс	294.383 мс	41.907 мс
W	543.763 мс	501.446 мс	42.317 мс
Загрузка	0.693527	0.701774	0.008247
λ_{eff}	3.342733 qps	3.389130 qps	0.046397

Полученные результаты показывают удовлетворительное совпадение теории и имитации. При $m = 5$ вероятность потерь уже ниже 5%, то есть базовый режим удовлетворяет критерию оптимальности.

Оптимизация длины очереди

Ниже приведены ключевые результаты подбора m .

m	P_{loss} теор.	P_{loss} сим.	W_q теор.	Условие $\leq 5\%$
0	0.420678	0.419116	0.000 мс	нет
1	0.233997	0.211697	87.279 мс	нет
2	0.145239	0.120507	163.952 мс	нет
3	0.095404	0.073899	230.540 мс	нет
4	0.064790	0.046517	287.721 мс	нет
5	0.044934	0.030714	336.290 мс	да
6	0.031598	0.020093	377.114 мс	да
7	0.022430	0.013126	411.088 мс	да
8	0.016027	0.008626	439.097 мс	да
9	0.011504	0.005903	461.985 мс	да
10	0.008285	0.004069	480.539 мс	да
11	0.005980	0.002675	495.464 мс	да
12	0.004324	0.002109	507.390 мс	да

Из таблицы видно, что:

- при малых значениях m вероятность потерь остается слишком высокой;
- начиная с $m = 5$ условие $P_{\text{loss}} \leq 0.05$ уже выполняется;
- при дальнейшем росте m потери уменьшаются, но среднее время ожидания продолжает расти.

Следовательно, оптимальным значением в исследованном диапазоне является минимальное допустимое значение

$$m^* = 5.$$

Область достижимости $P_{\text{loss}} \leq 5\%$

Чтобы понять, какие изменения действительно нужны для выполнения ограничения, были оценены три инженерных сценария:

- сохранение текущего потока $\lambda = 3.5$ qps и подбор требуемого μ_{eff} ;
- сохранение текущего сервера и подбор максимально допустимого входного потока;
- выбор компромиссных пар m и μ_{eff} .

m	Требуемый μ_{eff}	Требуемое $E[S]$	Макс. допустимый λ	Достижимо сейчас
5	4.697147 qps	212.895 мс	3.591470 qps	да
7	4.168124 qps	239.916 мс	4.047303 qps	да
10	3.810889 qps	262.406 мс	4.426700 qps	да

Из этой таблицы видно, что текущий сервер с $\mu_{\text{eff}} \approx 4.819904$ qps уже находится в допустимой области. Например, для базового буфера $m = 5$ достаточно поддерживать поток не выше $\lambda \approx 3.591470$ qps, а фактический выбранный поток $\lambda = 3.5$ qps этому условию удовлетворяет.

Проверка достижимого сценария

Чтобы показать запас по достижимости, был рассмотрен сценарий на верхней границе допустимого входного потока при $m = 5$:

- $m = 5$;
- $\lambda \approx 3.591470$ qps;
- $\mu_{\text{eff}} \approx 4.819904$ qps.

Показатель	Теория	Имитация	Абс. отклонение
P_{loss}	0.050000	0.034021	0.015979
W_q	349.505 мс	310.942 мс	38.563 мс
W	556.978 мс	517.926 мс	39.052 мс
Загрузка	0.707877	0.718959	0.011083

Имитация в этом сценарии также дает вероятность потерь ниже 5%, хотя из-за конечной длительности моделирования и случайности прогонов наблюдается некоторое отклонение от теоретической границы. Это подтверждает, что выбранный рабочий поток действительно лежит внутри допустимой области.

Сценарный анализ

Сценарий	m	P_{loss} теор.	W_q теор.	L_q теор.
Малый буфер	1	0.233997	87.279 мс	0.233997
Базовый режим	5	0.044934	336.290 мс	1.124127
Увеличенный буфер	7	0.022430	411.088 мс	1.406535
Большой буфер	10	0.008285	480.539 мс	1.667951

Сценарный анализ подтверждает компромисс между потерями и временем ожидания:

- малый буфер приводит к высокой вероятности отказа, но ожидание сравнительно невелико;
- базовый буфер $m = 5$ уже обеспечивает выполнение ограничения по потерям;
- дальнейшее увеличение буфера дополнительно снижает потери, но одновременно увеличивает среднее время ожидания и среднюю длину очереди.

Анализ результатов

Результаты экспериментов позволяют сделать следующие выводы.

1. Вероятность потерь монотонно убывает с ростом m . При выбранном потоке $\lambda = 3.5$ qps уже начиная с $m = 5$ достигается уровень ниже 5%.
2. Среднее время ожидания W_q растет с ростом m . Причина в том, что дополнительные места в очереди позволяют системе принять больше запросов, но эти запросы затем дольше ожидают обработки.
3. Для выбранных параметров системы $\lambda = 3.5$ qps и $\mu_{\text{eff}} \approx 4.82$ qps условие $P_{\text{loss}} \leq 5\%$ достигается. Минимальное значение, удовлетворяющее этому требованию, равно $m = 5$.
4. Теоретическая модель и имитационное моделирование согласуются по всем ключевым показателям, поэтому вывод о выборе оптимального буфера является устойчивым.
5. С практической точки зрения дальнейшее увеличение длины очереди после $m = 5$ уже не нужно: оно уменьшает потери, но расплачивается ростом времени ожидания.
6. Наиболее наглядный инженерный вывод для данной работы: при текущем сервере граница допустимого входного потока для $m = 5$ находится около $\lambda \approx 3.59$ qps, а выбранный рабочий поток $\lambda = 3.5$ qps обеспечивает небольшой запас по выполнению требования.

Заключение

В работе была исследована система массового обслуживания с ограниченной очередью типа М/М/1/м. Построены теоретическая и имитационная модели, выполнены расчеты основных характеристик и проведена оптимизация длины очереди по ограничению на вероятность потерь.

Важное замечание: при использовании предметной модели из ЛР2 эффективная интенсивность обслуживания оказывается равной $\mu_{\text{eff}} \approx 4.82$ qps, поэтому предложенная нагрузка

$$\rho = \frac{\lambda}{\mu_{\text{eff}}} \approx 0.73 < 1.$$

Это означает, что система находится в устойчивом режиме, а вероятность потерь может быть снижена подбором конечной длины очереди.

Таким образом, при использовании предметной модели из ЛР2 задача оптимизации длины очереди имеет корректное решение. В исследованном диапазоне минимальным значением, обеспечивающим вероятность потерь не более 5%, является

$$m^* = 5.$$

Практически это означает следующее:

- буфер $m = 5$ уже достаточен для выполнения ограничения $P_{\text{loss}} \leq 5\%$;
- увеличение буфера сверх этого значения уменьшает потери, но ухудшает время ожидания;
- гранично допустимый входной поток для текущего сервера и буфера $m = 5$ составляет примерно $\lambda \approx 3.59$ qps, поэтому выбранный режим $\lambda = 3.5$ qps имеет небольшой запас устойчивости.