





ІТМО

**Лекция 2. Введение в
экономику СМО**

Цель СМО

ИТМО



Основные компромиссы СМО

- Скорость / качество
- Сложность процесса / уровень сотрудника
- Стандартизация / кастомизация
 - Сложность СМО / сложность ансамбля СМО
 - Простота / масштабируемость
 - Простота / способность реакции на неожиданное
- Быстрый запуск / развиваемость в будущем
- Простота / универсальность (в смысле других применений)
- Прозрачность (**без компромиссов!**)



- Рисуем процесс обслуживания с ветвлениями
- Выявляем узловые точки, там делаем блоки вход-выход (горизонтальное разбиение)
- Выявляем независимые параллельные ветви обработки, делаем параллельные блоки (вертикальное разбиение)
- Оцениваем параметры нагрузки, учитываем при деплое
- Соотносим с административными границами и другими факторами



Факторы доходности СМО



- Количество заявок на обслуживание
- Результат успешного выполнения заявки
- Имидж при высоком качестве обслуживания
- Синергетический эффект ансамбля СМО

Расходные факторы СМО




- Затраты на обслуживание заявки
- Потери при отказах в обслуживании
- Затраты на управление и мониторинг СМО
- Самообусловленные процессы в ансамбле СМО
- Затраты на администрирование частично обработанных заявок
- Инвестиции в развитие СМО


Параметры СМО для экономического анализа:

- входящий поток требований или заявок на обслуживание;
 - правила фильтрации заявок
- дисциплина постановки в очередь и выбора из нее;
- правила, по которым осуществляется обслуживание;
 - правила частичного обслуживания заявки в ансамбле систем;
- выходящий поток требований (вход следующей СМО);
- режимы работы СМО.

Система массового обслуживания с параллельной обработкой



- **Закон поступления требований в систему**
 - Интенсивность + распределение по времени
 - Распределение временных интервалов между заявками
- **Правила входной фильтрации обращений**
 - По распределению характеристик (пороги)
 - По параметрическим критериям
 - По характеристикам СМО в момент поступления заявки (с обратной связью)



Дисциплина управления очередью

- Порядок **постановки** заявки в очередь
 - FIFO
 - LIFO
 - Random
 - Постановка по параметрам
 - Выборка по параметрам заявки
- **Ограничения на параметры** очереди
 - Длина (неограниченная, ограниченная)
 - Время ожидания в очереди
 - Приоритеты
- **Организация очередей в системе**



Правила обслуживания в очереди

- **Длительность** обслуживания
 - Фиксированная / детерминированная
 - Случайная, заданная функцией распределения
 - Параметрическая (заданная по параметрам заявки)
- Количество **каналов обслуживания**
- Количество **фаз обслуживания**
 - Однофазная СМО
 - Многофазная СМО
 - Многофазная СМО с возвратами



Приоритет



- Беспriorитетная (в порядке очереди)
- Приоритет
 - Статический
 - Динамический
 - С обратной связью
- Приоритезация
 - Вытесняющая / Абсолютная
 - Корпоративная / Относительная

Политика обработки отказов



- Отказ в обслуживании
- Возврат в очередь
- Перераспределение в очередь
- Вероятность / распределение возвратов
- Дисциплина возврата



Для СМО любого вида
для *любого распределения времени* между двумя событиями
поступления требований,
любого распределения времени их обслуживания,
любого количества устройств обслуживания и
любой дисциплины обслуживания
среднее количество требований в СМО определяется через
интенсивность поступления и среднее время пребывания
требований в системе T , то есть:

$$\bar{N} = \lambda T$$

Экономический анализ СМО

ІТМО

- вероятность обслуживания клиента системой;
- пропускная способность системы;
- вероятность отказа клиенту в обслуживании;
- вероятность занятости каждого из канала и всех вместе;
- среднее время занятости каждого канала;
- вероятность занятости всех каналов;
- среднее количество занятых каналов;
- вероятность простоя каждого канала;
- вероятность простоя всей системы;
- среднее количество заявок, стоящих в очереди;
- среднее время ожидания заявки в очереди;
- среднее время обслуживания заявки;
- среднее время нахождения заявки в системе.



Сущность имитационного моделирования



Имитационные модели создают для исследования процессов со **сложной** зависимостью от некоторых **случайных** факторов. В имитационной модели случайные факторы моделируются при помощи специальных **генераторов** случайных величин.

Для получения характеристик системы имитационная модель **многократно** реализуется на компьютере. Полученный ряд значений исследуемого параметра подвергается **статистической обработке**, в результате которой определяются характеристики случайных показателей процесса - матожидание, дисперсия, закон распределения и т. п.

Моделирование сложных СМО – хорошее применение методов Монте-Карло!



Оптимизация — процесс поиска наилучшего решения задачи в   рамках заданных ограничений.

- **Локальная оптимизация** — поиск наилучшего решения в окрестности начального приближения.
 - Используется, когда целевая функция имеет несколько локальных экстремумов, и **достаточно** найти один из них.
 - Градиентный спуск, метод Ньютона.
- **Глобальная оптимизация** — поиск наилучшего решения на всей области определения целевой функции.
 - Используется, когда целевая функция имеет множество локальных экстремумов, и необходимо найти **наилучший** из них.
 - Генетические алгоритмы, метод Монте-Карло, имитация отжига.

Линейная оптимизация — целевая функция и ограничения являются линейными функциями переменных.



$$f(x) = c_1x_1 + c_2x_2 + \dots + c_nx_n,$$

где c_i — коэффициенты, x_i — переменные.

- Симплекс-метод, метод внутренних точек.

Глобальная нелинейная оптимизация — целевая функция или ограничения являются нелинейными функциями переменных.

$$f(x) = c_1x_1^2 + c_2\sin(x_2) + \dots + c_n e^{x_n},$$

где c_i — коэффициенты, x_i — переменные.

- Градиентный спуск, метод Ньютона, генетические алгоритмы.

Минимизация на Python

```
from scipy.optimize import minimize
```

```
# Определение функции
```

```
def f(x):
```

```
    return x**2 + 3*x + 4 # Функция одной переменной
```

$$f(x) = x^2 + 3x + 4.$$

```
# Начальное предположение
```

```
x0 = 0
```

```
# Минимизация
```

```
result = minimize(f, x0)
```

```
# Определение функции
```

```
def f(params):
```

```
    x, y = params
```

```
    return (x - 1)**2 + (y - 2)**2 # Функция двух переменных
```

$$f(x, y) = (x - 1)^2 + (y - 2)^2$$

```
# Начальное предположение
```

```
x0 = [0, 0]
```

```
# Минимизация
```

```
result = minimize(f, x0)
```

```
# Ограничение
```

```
constraint = {'type': 'eq', 'fun': lambda params: params[0] + params[1] - 3}
```

$$x + y = 3.$$

```
# Минимизация с ограничением
```

```
result = minimize(f, x0, constraints=constraint)
```





Глобальная оптимизация.

```
from scipy.optimize import basinhopping
# Определение функции
def f(x):
    return x**2 + 10 * np.sin(x)

# Начальное предположение
x0 = 0

# Глобальная минимизация
result = basinhopping(f, x0)
```

Градиентный спуск.

```
from scipy.optimize import minimize

# Определение функции и градиента
def f(params):
    x, y = params
    return (x - 1)**2 + (y - 2)**2
def grad_f(params):
    x, y = params
    return np.array([2*(x - 1), 2*(y - 2)])

# Начальное предположение
x0 = [0, 0]

# Минимизация с использованием градиента
result = minimize(f, x0, jac=grad_f)
```

Минимизация на Python

Минимизация по МНК



```
import numpy as np
from scipy.optimize import least_squares
import matplotlib.pyplot as plt

# Определение модели
def model(params, x):
    a, b, c = params
    return a * np.sin(b * x) + c

# Определение функции ошибки
def error(params, x, y):
    return model(params, x) - y

# Генерация данных
x_data = np.linspace(0, 10, 100)
y_data = 2 * np.sin(1.5 * x_data) + 3 + np.random.normal(0, 0.5, 100)

# Начальное предположение
x0 = [1, 1, 1]

# Подбор параметров
result = least_squares(error, x0, args=(x_data, y_data))

# Визуализация
plt.scatter(x_data, y_data, label='Данные')
plt.plot(x_data, model(result.x, x_data), color='red', label='Модель')
plt.legend()
plt.show()
```

Имитация отжига



```
import math
import random

def simulated_annealing(f, x0, T0, alpha, max_iter):
    x = x0
    T = T0
    for i in range(max_iter):
        x_new = x + random.uniform(-1, 1) # Генерация нового решения
        delta_E = f(x_new) - f(x)
        if delta_E < 0 or random.random() < math.exp(-delta_E / T):
            x = x_new # Принятие нового решения
        T *= alpha # Охлаждение
    return x

# Пример целевой функции
def f(x):
    return x**2 + 3 * x + 4

# Запуск алгоритма
x0 = 10 # Начальное решение
T0 = 100 # Начальная температура
alpha = 0.95 # Коэффициент охлаждения
max_iter = 1000 # Максимальное число итераций

result = simulated_annealing(f, x0, T0, alpha, max_iter)
```

Поиск полиномиальной аппроксимации.



```
import numpy as np
from scipy.optimize import curve_fit
import matplotlib.pyplot as plt

# Определение линейной модели
def linear_model(x, a, b):
    return a * x + b

# Генерация данных
x_data = np.linspace(0, 10, 100)
y_data = 2 * x_data + 3 + np.random.normal(0, 1, 100)

# Подбор параметров
params, _ = curve_fit(linear_model, x_data, y_data)

# Визуализация
plt.scatter(x_data, y_data, label='Данные')
plt.plot(x_data, linear_model(x_data, *params), color='red', label='Модель')
plt.legend()
plt.show()
```

Целевые функции СМО

В зависимости от специфики моделируемой СМО и её **назначения** необходимо подобрать релевантную целевую функцию.



Целевая функция измеряется при предварительных прогонах модели, когда меняются управляемые факторы.

Каждый прогон представляет собой реализацию случайного процесса, поэтому оценивается также «стоимость» и «значимость»: **количество прогонов** и **длительность моделирования**, для достижения статистически значимой оценки.

Управляемые факторы:



- Количество каналов N
- Интенсивность обслуживания μ (скорость работы)
- Дисциплина очереди (FIFO, приоритеты, длина)

Ограничения:

- Допустимая доля отказов
- Бюджет на каналы / число каналов
- Время ожидания (норма или стандарт)

ЦФ: Минимизация стоимости при заданном качестве



$$F = c_{\text{кан}} \cdot N + c_{\text{ож}} \cdot W_q$$

$c_{\text{кан}}$ — стоимость одного канала в ед. времени

N — число каналов

$c_{\text{ож}}$ — стоимость ожидания одной заявки в ед. времени

W_q — среднее время ожидания в очереди

ЦФ: Максимизация прибыли

$$F = \lambda_{\text{обсл}} \cdot p_{\text{усл}} - c_{\text{кан}} \cdot N - c_{\text{потерь}} \cdot \lambda_{\text{отказ}}$$

$\lambda_{\text{обсл}}$ — интенсивность обслуженных заявок

$p_{\text{усл}}$ — доход от одной обслуженной заявки

$c_{\text{кан}}$ — затраты на канал

$\lambda_{\text{отказ}}$ — интенсивность отказов

$c_{\text{потерь}}$ — потери от отказа

Управляемые факторы:



- Размер партии
- Страховой запас
- Приоритеты обработки
- Количество станков на операциях
- Скорость конвейера
- Число рабочих смен
- Буферы между операциями

Ограничения:

- Выпуск $\geq$ план
- Свободная площадь склада
- Брак $\leq$ норма
- Ресурс оборудования

ЦФ: Минимизация затрат при выполнении плана



$$F = c_{\text{прост}} \cdot T_{\text{простой}} + c_{\text{склад}} \cdot Q_{\text{запас}} + c_{\text{переналадка}} \cdot K_{\text{переналадка}}$$

$c_{\text{прост}}$ — стоимость простоя оборудования

$T_{\text{простой}}$ — суммарное время простоя

$c_{\text{склад}}$ — стоимость хранения единицы продукции

$Q_{\text{запас}}$ — средний уровень запаса

$c_{\text{переналадка}}$ — стоимость одной переналадки

$K_{\text{переналадка}}$ — число переналадок

ЦФ: Максимизация пропускной способности

$$F = \sum_i \text{Out}_i$$

Out_i — количество годных изделий типа i за период

Управляемые факторы:



- Пропускная способность каналов
- Алгоритм маршрутизации
- Размер буферов
- Распределение полосы
- Приоритезация трафика

Ограничения:

- Потери $\leq$ допустимый уровень
- Джиттер $\leq$ норма

ЦФ: Минимизация задержек



$$F = \sum_i \text{Delay}_i$$

Delay_i — средняя задержка пакета для потока i

ЦФ: Максимизация пропускной способности

$$F = \sum_i \text{Throughput}_i$$


Throughput_i — успешно доставленный трафик для потока i

... что именно надо сделать — увеличивать количество каналов или увеличивать их пропускную способность, или увеличивать количество мест в очереди, и, если увеличивать, то насколько? Что лучше — создать 3 канала с производительностью 5 заявок/час или один с производительностью 15 заявок/час?..






Метод покоординатного спуска




- Фиксируем все параметры кроме одного;
- Вычисляем значение всех показателей при нескольких значениях этого выбранного параметра;
- Повторяем процедуру имитации и усредняем показатели при каждом значении параметра, оценивая точность;
- Производим статистическую и аналитическую обработку графиков – якобиан системы.



Как принять решение о значениях?



А как учесть риски?



Характеристики СМО

Многоканальная СМО с неограниченной очередью



λ – среднее число заявок, поступающих за единицу времени

t – среднее время обслуживания заявки

$\mu = 1/t$ – среднее число заявок, обслуживаемых за единицу времени

$\alpha = \lambda / \mu$ – среднее число занятых каналов

n – общее число каналов

Вероятность того, что
все n каналов свободны

$$P_0 = \frac{1}{\left(\sum_{k=0}^{n-1} \frac{\alpha^k}{k!} \right) + \frac{\alpha^n}{n!(1 - \alpha / n)}}$$

Характеристики СМО (2)

λ – среднее число заявок, поступающих за единицу времени

t – среднее время обслуживания заявки

$\mu = 1/t$ – среднее число заявок, обслуживаемых за единицу времени

$\alpha = \lambda/\mu$ – среднее число занятых каналов

n – общее число каналов



Вероятность того, что
свободно $n - k$ каналов

$$P_k = \frac{\alpha^k}{k!} P_0, \quad 1 \leq k \leq n$$

Вероятность наличия очереди
из $k - n$ заявок

$$P_k = \frac{\alpha^k}{n! \cdot n^{k-n}} P_0, \quad k \geq n$$

Характеристики СМО (3)

λ – среднее число заявок, поступающих за единицу времени

t – среднее время обслуживания заявки

$\mu = 1/t$ – среднее число заявок, обслуживаемых за единицу времени

$\alpha = \lambda/\mu$ – среднее число занятых каналов

n – общее число каналов



Вероятность наличия очереди

Средняя длина очереди

$$P_Q = \frac{\alpha^{n+1}}{n!(n-\alpha)} P_0, \quad \alpha < n$$

$$L_Q = \frac{\alpha}{n-\alpha} P_k, \quad k = n, \alpha < n$$

Характеристики СМО (3)

λ – среднее число заявок, поступающих за единицу времени

t – среднее время обслуживания заявки

$\mu = 1/t$ – среднее число заявок, обслуживаемых за единицу времени

$\alpha = \lambda / \mu$ – среднее число занятых каналов

n – общее число каналов



Среднее время ожидания

$$t_q = \frac{L_q}{\lambda}$$

Коэффициент простоя каналов

$$K_s = 1 - \alpha / n$$

Необходимое условие работоспособности СМО

$$\alpha < n$$