



**ІТМО**

**Лекция 8. Общая схема анализа  
СМО.**

# Общий алгоритм изучения СМО

1. Сформулировать цель: **целевая функция**
2. Определить границы системы: **внешние потоки**
3. Оценить параметры:  **$\lambda$ ,  $\mu$ , распределения, число каналов**
4. Выбрать метод моделирования: **решение по методу и архитектура**
5. Построить модель: **уравнения / код / правила агентов**
6. Проверить модель: **верификация**
7. Спланировать эксперимент: **диапазоны параметров, план прогонов**
8. Выполнить предварительные расчёты, оценить: **валидация**
9. Выполнить расчеты по плану: **массив выходных данных**
10. Статистически обработать: **оценки показателей**
11. Принять решение: **выбрать конфигурацию, дать рекомендации**




Параметры СМО для экономического анализа:



- **входящий поток требований или заявок на обслуживание;**
  - **правила фильтрации заявок**
- **дисциплина постановки в очередь и выбора из нее;**
- **правила, по которым осуществляется обслуживание;**
  - **правила частичного обслуживания заявки в ансамбле систем;**
- **выходящий поток требований (вход следующей СМО);**
- **режимы работы СМО.**

- **Закон поступления требований в систему**
  - Интенсивность + распределение по времени
  - Распределение временных интервалов между заявками
- **Правила входной фильтрации обращений**
  - По распределению характеристик (пороги)
  - По параметрическим критериям
  - По характеристикам СМО в момент поступления заявки (с обратной связью)



# Дисциплина управления очередью

- Порядок **постановки** заявки в очередь
  - FIFO
  - LIFO
  - Random
  - Постановка по параметрам
  - Выборка по параметрам заявки
- **Ограничения на параметры** очереди
  - Длина (неограниченная, ограниченная)
  - Время ожидания в очереди
  - Приоритеты
- **Организация очередей в системе**



# Правила обслуживания в очереди

- **Длительность** обслуживания
  - Фиксированная / детерминированная
  - Случайная, заданная функцией распределения
  - Параметрическая (заданная по параметрам заявки)
- **Количество каналов обслуживания**
- **Количество фаз обслуживания**
  - Однофазная СМО
  - Многофазная СМО
  - Многофазная СМО с возвратами



Фильтрация заявок позволяет отсеивать невыгодные или проблемные запросы, оптимизируя нагрузку на систему и увеличивая прибыль.



- Типы фильтрации
  - По приоритету
  - По сложности запроса
  - По платежеспособности
  - На основе балансировки нагрузки



Фильтрация по приоритету - Разделение заявок на классы (например, VIP, стандарт, эконом) с разными условиями обслуживания.

- Динамический приоритет  $P_i = \frac{R_i}{T_i}$
- - $R_i$  – доход от заявки,  $T_i$  – ожидаемое время обслуживания.
- Платный приоритет – клиенты могут оплатить ускоренное обслуживание (аналог «fast track» в аэропортах).
- На основе балансировки нагрузки:  $\rho = \frac{\lambda}{n\mu}$

Если система перегружена ( $\rho \geq 0.8$ ), фильтровать заявки жестче



Фильтрация по сложности - отсеив заявок, которые требуют слишком много ресурсов или имеют низкую вероятность успешного завершения.



- Снижение нагрузки на дорогие ресурсы (например, квалифицированных сотрудников).
- Рост общего дохода на 10–20% за счет концентрации на рентабельных заявках.

Фильтрация по платежеспособности - предварительная проверка клиентов (кредитоспособность, история платежей).

- Сокращение безнадежных долгов на 25–40%.
- Уменьшение затрат на взыскание.

## Инструменты.



- AI-классификаторы (бьянка для анализа текста заявки).
- Скоринговые системы (на основе CRM-данных).
- Динамическое ценообразование (например, повышение тарифа для «сложных» запросов).

## Общий алгоритм:

- Внедрить приоритезацию: разделить заявки на VIP/стандарт;
- Отсекать убыточные заявки: использовать пороговые правила;
- Автоматизировать фильтрацию: чат-боты, скоринговые системы;
- Динамически подстраивать фильтры: ужесточать отбор при перегрузке;
- Автоматически подстраивать тарифы и условия обслуживания.

- **FIFO (First In, First Out)** – первым пришел, первым обслужен.
- **Экономика:** проста в реализации, но может приводить к большим задержкам для высокоприоритетных клиентов.
- **LIFO (Last In, First Out)** – последним пришел, первым обслужен.
- **Экономика:** может улучшать среднее время ожидания для новых заявок, но увеличивает несправедливость.





- **Приоритетное обслуживание** – заявки с высоким приоритетом обслуживаются первыми.
- **Экономика**: повышает удовлетворенность важных клиентов, но может ухудшать средние показатели для остальных.
- **RR (Round Robin)** – циклическое обслуживание с квантом времени.
- **Экономика**: обеспечивает справедливость, но может снижать общую пропускную способность.



- **PS (Processor Sharing)** – все заявки обслуживаются "одновременно" с разделением ресурса.
- **Экономика:** минимизирует вариативность времени ожидания, но требует сложного управления.



- **Ограничение очереди** (например, отказ при переполнении).
- **Экономика**: снижает перегрузку, но ведет к потерям заявок.
- **Динамическое управление** (например, добавление серверов при росте нагрузки).
- **Экономика**: требует затрат на масштабирование, но улучшает качество обслуживания.



- **Раздельные очереди** (например, fast lane и regular lane).
- **Экономика:** позволяет дифференцировать услуги по цене.
- **Единый пул с балансировкой** (например, виртуальная очередь в банках).
- **Экономика:** повышает эффективность использования ресурсов.

## Метрики



- **Среднее время ожидания** – влияет на удовлетворенность клиентов.
- **Коэффициент загрузки** – определяет эффективность использования ресурсов.
- **Вероятность отказа** – потери из-за перегруженности.
- **Стоимость обслуживания** – затраты на инфраструктуру и персонал.



## Методы анализа и оптимизации



- **Теория очередей** (Марковские процессы, формулы Эрланга) – для расчета стационарных характеристик.
- **Имитационное моделирование** – для сложных систем с нестандартными дисциплинами.
- **Эконометрические подходы** – анализ реальных данных для настройки параметров.

Сравнение общей очереди и нескольких параллельных очередей в многоканальной СМО



- **Одна общая очередь (Single Queue, SQ)** – все заявки попадают в единый пул и распределяются на свободные серверы.
- **Несколько параллельных очередей (Multiple Queues, MQ)** – у каждого сервера своя очередь, заявка выбирает одну из них (например, случайно или по наименьшей длине).

- Среднее число заявок в очереди



$$L_q = \frac{P_0 \cdot \left(\frac{\lambda}{\mu}\right)^n \cdot \rho}{n!(1 - \rho)^2} \quad P_0 = \left[ \sum_{k=0}^{n-1} \frac{(\lambda/\mu)^k}{k!} + \frac{(\lambda/\mu)^n}{n!(1 - \rho)} \right]^{-1}$$

- Среднее время ожидания  $W_q = \frac{L_q}{\lambda}$

- Среднее время в системе  $W = W_q + \frac{1}{\mu}$

- Среднее время ожидания в одной очереди



$$W_q^{(i)} = \frac{\rho_i}{\mu(1 - \rho_i)}, \quad \rho_i = \frac{\lambda_i}{\mu}.$$

- Общее среднее время ожидания

$$W_q^{\text{MQ}} = W_q^{(i)} = \frac{\rho}{\mu(n - \lambda/\mu)}$$

- Среднее время ожидания в одной очереди



$$W_q^{\text{SQ}} \approx \frac{\rho \cdot C(n, \rho)}{\lambda(1 - \rho)}$$

- Среднее время ожидания в параллельных очередях

$$W_q^{\text{MQ}} = \frac{\rho}{\mu(n - \lambda/\mu)}$$

Когда выбирать **общую очередь**?



- **Высокая стоимость простоя** клиентов (например, call-центры, банки).
- Важна **минимизация** времени ожидания.

Когда выбирать **параллельные очереди**?

- **Низкие** требования к времени ожидания.
- **Ограниченные** ресурсы на управление очередями (например, супермаркеты с кассами).

# «Лайфхак» - какой я умный

Рассмотрим систему с несколькими каналами, где:



- Часть заявок («наивные») встает только в одну случайную очередь (как в классической многоканальной СМО).
- Часть заявок («умные») встает **во все очереди** (как в системе с дублированием).

# «Лайфхак» - какой я умный

Время ожидания:



- «Наивные»

$$W_q^{\text{ordinary}} \approx \frac{C(n, \rho_{\text{eff}})}{n\mu - \lambda_{\text{ordinary}}}$$

- «Умные»

$$W_q^{\text{priority}} \approx \frac{1}{n\mu - \lambda_{\text{priority}}}$$

- Умные заявки **выигрывают значительно** (время ожидания ↓, удовлетворенность ↑).
- Обычные заявки **проигрывают**, но это может быть оправдано экономически.
- Оптимальная стратегия требует анализа доходов и потерь для обеих групп.



# Выбор метода моделирования ИТМО



| Ситуация                                                       | Аналитика             | Имитация                    | Агенты            |
|----------------------------------------------------------------|-----------------------|-----------------------------|-------------------|
| Поток – пуассоновский, обслуживание – экспоненциальное         | ✓ идеал               | ✗ избыточно                 | ✗ не нужно        |
| Распределения произвольные (G/G/n)                             | ✗ нет формул          | ✓ подходит                  | ♦ можно, но зачем |
| Замкнутая сеть с 5–20 заявками                                 | ✓ MVA                 | ♦ допустимо                 | ✗                 |
| Толпа, эвакуация, водители... иначе говоря, есть адаптивность. | ✗                     | ♦ ограниченно               | ✓ лучший          |
| Нужна точная вероятность отказа в редких событиях              | ✓ (если есть формула) | ✗ (нужны миллионы прогонов) | ✗                 |
| Высокая размерность (>10 узлов, сложная маршрутизация)         | ✗                     | ✓                           | ♦                 |

# Типичные ошибки



| Ошибка                                                                         | Почему плохо                                | Как правильно                                                           |
|--------------------------------------------------------------------------------|---------------------------------------------|-------------------------------------------------------------------------|
| Сразу браться за агентное моделирование, когда есть Пуассон одинаковых заявок. | Сложность неоправданна, достаточно М/М/п    | Оценить, <b>есть ли адаптивное поведение</b> (нет → имитация/аналитика) |
| Использовать имитацию, когда есть формула Эрланга                              | Тратим время, теряем точность               | Проверить, <b>выполняется ли М/М/п</b>                                  |
| Применять аналитику для сети с приоритетами и нетерпеливыми заявками           | Формулы нет → результат неверен             | Имитация или адаптированная MVA (если повезёт...)                       |
| Делать мало прогонов имитации                                                  | Случайная погрешность принимается за истину | Оценить <b>доверительный интервал</b> , делать максимум прогонов.       |

$L = \lambda \times W$  — работает **всегда**, даже если распределения не экспоненциальные.



**Правило:** если можно оценить среднее время пребывания  $W$  из предметной области → можно грубо оценить среднюю длину очереди  $L$ . Отбраковать **заведомо плохие** решения.

**Пример:**  $\lambda = 10$  заявок/мин,  $L < 5$ , то  $W < 0.5$  мин. Если по опыту обслуживание  $\sim 1$  мин — сразу ясно, что нужно несколько каналов.

**Закон Литтла — фильтр первого уровня** перед любым моделированием.

Правило моделирования СМО:



- **Простейшие** системы – аналитика.
- **Переменные** (неэкспоненциальные, зависимые) – имитация.
- **Поведенческие** (микрорешения, адаптивность) – агентная модель.

*Модель не должна быть сложнее, чем это необходимо для ответа на вопрос.*